

## 第 8 章补充材料

### ● 矢量与坐标系

特征矢量一般都是以坐标的形式表示的,矢量的每一个分量是它在相应坐标轴上的投影。坐标系可以用坐标原点  $O$  和一组代表各个坐标轴的“基矢量” $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_d\}$  来表示,如果基矢量之间满足如下关系:

$$\mathbf{e}_i^t \mathbf{e}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \quad (1)$$

则称这组基矢量构成了一个标准正交系,所谓“标准”是指每个矢量的长度均为  $1$ ,所谓“正交”是指任意两个矢量之间是正交的。这样构成的坐标系就是我们所熟悉的直角坐标系。

如图 1 所示,在一个直角坐标系下,矢量  $\mathbf{x} = (x_1, \dots, x_d)^t$  可以表示为基矢量的线性组合:

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + \dots + x_d \mathbf{e}_d = \sum_{i=1}^d x_i \mathbf{e}_i \quad (2)$$




图 1 矢量和直角坐标系

很显然,根据 (1) 和 (2) 式,我们可以通过计算矢量  $\mathbf{x}$  与基矢量  $\mathbf{e}_j$  的内积来得到相应的坐标分量:

$$\mathbf{x}^t \mathbf{e}_j = \sum_{i=1}^d x_i \mathbf{e}_i^t \mathbf{e}_j = x_j \quad (3)$$

## ● 主成分分析算法的推导

我们知道，样本集合中的每一个样本都对应着特征空间中的一个点，同样的一个样本点在不同坐标系下对应着不同的矢量，例如图 2 中某个样本对应着特征空间中的点 A，在以 O 为坐标原点  $\{\mathbf{v}_1, \mathbf{v}_2\}$  为基矢量的原坐标系下 A 点对应的矢量是  $\mathbf{x}$ ，而在 O' 为原点  $\{\mathbf{e}_1, \mathbf{e}_2\}$  为基矢量的新坐标系下对应的矢量是  $\mathbf{x}'$ ，如果新坐标系的原点 O' 在原坐标系下对应的矢量是  $\boldsymbol{\mu}$ ，显然有如下关系：

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{x}' \quad (1)$$

这个关系虽然是从 2 维空间中得到的，在高维空间中同样成立。

分别将矢量  $\mathbf{x}$  和  $\mathbf{x}'$  写成两个坐标系下的坐标形式： $\mathbf{x} = (x_1, \dots, x_d)^t$ ， $\mathbf{x}' = (a_1, \dots, a_d)^t$ ，(1) 式可以表示为：

$$\mathbf{x} = \boldsymbol{\mu} + \sum_{i=1}^d a_i \mathbf{e}_i \quad (2)$$




图 2 同一个样本在不同坐标系下的表示

在新坐标系下，矢量  $\mathbf{x}'$  的元素可以由原坐标系下的矢量  $\mathbf{x}$  以及  $\boldsymbol{\mu}$  和基矢量  $\{\mathbf{e}_1, \dots, \mathbf{e}_d\}$  计算得到：

$$a_i = \mathbf{e}_i^t (\mathbf{x} - \boldsymbol{\mu}), \quad i = 1, \dots, d \quad (3)$$

同样也可以根据 (2) 式由新坐标下的矢量  $\mathbf{x}'$  来恢复原矢量  $\mathbf{x}$ ，不会存在任何误差。然而如果我们只保留新坐标系下  $d' < d$  个元素，然后用保留的  $d'$  个元素来恢复原坐标系下的  $d$  维矢量：

$$\hat{\mathbf{x}} = \boldsymbol{\mu} + \sum_{i=1}^{d'} a_i \mathbf{e}_i \quad (4)$$

显然  $\hat{\mathbf{x}}$  只是对  $\mathbf{x}$  的近似，用  $\hat{\mathbf{x}}$  来代替  $\mathbf{x}$  就会出现一定的误差，误差的大小同新坐标系的位置、基矢量的方向以及保留哪些特征有关。

在主成分分析方法中，新坐标系的原点选择在训练样本集  $D = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$  的均值矢量  $\boldsymbol{\mu}$  上，然后寻找一组最优的基矢量  $\{\mathbf{e}_1, \dots, \mathbf{e}_d\}$ ，使得在只保留前  $d'$  个元素的条件下，由新的坐标根据 (4) 式恢复样本集  $D$  的均方误差最小，即求解如下的优化问题：

$$\min_{\mathbf{e}_1, \dots, \mathbf{e}_d} J(\mathbf{e}_1, \dots, \mathbf{e}_d) = \frac{1}{n} \sum_{k=1}^n \|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2 \quad (5)$$

其中  $\hat{\mathbf{x}}_k$  是根据 (3) 式将  $\mathbf{x}_k$  由原坐标系变换到新坐标系下, 然后再根据 (4) 式只使用前  $d'$  个特征恢复的近似矢量。如果用  $a_{ki}$  表示第  $k$  个样本在新坐标系下的第  $i$  维特征, 由 (2) 式和 (4) 式可以得到:

$$\mathbf{x}_k - \hat{\mathbf{x}}_k = \sum_{i=d'+1}^d a_{ki} \mathbf{e}_i \quad (6)$$

代入到 (5) 式:

$$\begin{aligned} J(\mathbf{e}_1, \dots, \mathbf{e}_d) &= \frac{1}{n} \sum_{k=1}^n \|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2 = \frac{1}{n} \sum_{k=1}^n \left\| \sum_{i=d'+1}^d a_{ki} \mathbf{e}_i \right\|^2 \\ &= \frac{1}{n} \sum_{k=1}^n \left( \sum_{i=d'+1}^d a_{ki} \mathbf{e}_i \right)^t \left( \sum_{i=d'+1}^d a_{ki} \mathbf{e}_i \right) \\ &= \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^d a_{ki}^2 \\ &= \frac{1}{n} \sum_{k=1}^n \sum_{i=d'+1}^d [\mathbf{e}_i^t (\mathbf{x}_k - \boldsymbol{\mu})] [\mathbf{e}_i^t (\mathbf{x}_k - \boldsymbol{\mu})]^t \\ &= \sum_{i=d'+1}^d \mathbf{e}_i^t \left[ \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^t \right] \mathbf{e}_i \end{aligned}$$

其中第 2 行到第 3 行利用了  $\{\mathbf{e}_1, \dots, \mathbf{e}_d\}$  是新坐标系的基矢量, 因此构成了一个标准正交系:

$$\mathbf{e}_i^t \mathbf{e}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}, \quad i, j = 1, \dots, d$$

而第 3 行到第 4 行则是基于如下事实:  $a_{ki}$  是一个标量, 它的转置与其自身相等, 并且有 (3) 式成立, 因此  $a_{ki} = \mathbf{e}_i^t (\mathbf{x}_k - \boldsymbol{\mu}) = [\mathbf{e}_i^t (\mathbf{x}_k - \boldsymbol{\mu})]^t$ 。如果定义矩阵:

$$\boldsymbol{\Sigma} = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^t$$

恰好是样本集  $D$  的协方差矩阵, 则 (5) 式的优化问题变为:

$$\min_{\mathbf{e}_1, \dots, \mathbf{e}_d} J(\mathbf{e}_1, \dots, \mathbf{e}_d) = \sum_{i=d'+1}^d \mathbf{e}_i^t \boldsymbol{\Sigma} \mathbf{e}_i \quad (7)$$

仔细观察 (7) 式会发现, 直接求解这个优化问题是没有意义的。由于  $\boldsymbol{\Sigma}$  是半正定矩阵, 因此当  $\mathbf{e}_1, \dots, \mathbf{e}_d = \mathbf{0}$  时取得最小值 0, 显然零矢量并不能作为基矢量, 导致这样结果的原因在于优化 (7) 式时没有约束  $\mathbf{e}_1, \dots, \mathbf{e}_d$  的长度。主成分分析在求解新坐标系的基矢量时优化的是如下的约束问题:

$$\min_{\mathbf{e}_1, \dots, \mathbf{e}_d} J(\mathbf{e}_1, \dots, \mathbf{e}_d) = \sum_{i=d'+1}^d \mathbf{e}_i^t \boldsymbol{\Sigma} \mathbf{e}_i \quad (8)$$

约束:

$$\|\mathbf{e}_i\|^2 = 1, \quad i = 1, \dots, d$$

有约束优化问题可以通过构造 Lagrange 函数转化为无约束问题(参见最优化方法 VI):

$$L(\mathbf{e}_1, \dots, \mathbf{e}_d, \lambda_1, \dots, \lambda_d) = \sum_{i=d'+1}^d \mathbf{e}_i^t \Sigma \mathbf{e}_i - \sum_{i=d'+1}^d \lambda_i (\mathbf{e}_i^t \mathbf{e}_i - 1) \quad (9)$$

对每一个基矢量  $\mathbf{e}_j$  求导数:

$$\frac{\partial L(\mathbf{e}_1, \dots, \mathbf{e}_d, \lambda_1, \dots, \lambda_d)}{\partial \mathbf{e}_j} = 2\Sigma \mathbf{e}_j - 2\lambda_j \mathbf{e}_j = 0 \quad (10)$$

其中利用到了  $\Sigma$  为对称矩阵的事实。由此得到优化问题 (8) 的解应满足:

$$\Sigma \mathbf{e}_j = \lambda_j \mathbf{e}_j \quad (11)$$

显然, 使得上式成立的  $\lambda_j$  和  $\mathbf{e}_j$  分别为矩阵  $\Sigma$  的特征值和对应的特征矢量。由此我们可以得到这样的结论: 如果我们希望将一个样本集合  $D$  中的  $d$  维特征矢量在一个新的坐标系下只用  $d'$  个特征进行表示, 那么应该将新坐标系的坐标原点放在  $D$  的均值  $\mu$  的位置, 而以集合  $D$  的协方差矩阵的特征矢量  $\mathbf{e}_1, \dots, \mathbf{e}_d$  作为基矢量, 这样可以保证只用保留的  $d'$  维特征恢复原矢量时均方误差最小。

通过这样的方式可以得到一个最优的新坐标系, 注意到  $\Sigma$  是一个  $d \times d$  的矩阵, 存在  $d$  个特征值和特征矢量, 现在的问题是我们只希望保留新坐标系中的  $d'$  个坐标, 应该保留哪些坐标才能够保证恢复出的  $d$  维特征矢量的均方误差最小? 回到优化问题 (8), 将 (11) 式代入优化函数:

$$J(\mathbf{e}_1, \dots, \mathbf{e}_d) = \sum_{i=d'+1}^d \mathbf{e}_i^t \Sigma \mathbf{e}_i = \sum_{i=d'+1}^d \lambda_i \mathbf{e}_i^t \mathbf{e}_i = \sum_{i=d'+1}^d \lambda_i \quad (12)$$

要使得  $J(\mathbf{e}_1, \dots, \mathbf{e}_d)$  最小, 只需要选择  $\lambda_{d'+1}, \dots, \lambda_d$  是  $\Sigma$  最小的  $d-d'$  个特征值。这里需要注意一点, 在整个推导过程中我们约定的是要保留新坐标系下前  $d'$  个特征, 而放弃掉后面的  $d-d'$  个特征, 因此新的坐标系下应该选择保留的是  $\Sigma$  最大的  $d'$  个特征值对应的特征矢量作为新坐标系的基矢量。

## ● 基于 Fisher 准则的可分性分析算法的推导

样本下面先从一种简单的情况入手来研究这个问题，我们将两个类别的样本向一条通过坐标原点的直线上投影，也就是用 1 维特征来表示  $d$  维矢量，希望在 1 维空间中两类样本的可分性最大。从图 3 可以看出在不同方向的直线上，两类样本的可分性是不同的，如果想要找到一个最优的投影直线方向，首先需要对 1 维空间中样本的可分性进行度量。




图 3 二维模式在一维空间的投影

假设两类问题的样本集为：  $D_1 = \{\mathbf{x}_1^{(1)}, \dots, \mathbf{x}_{n_1}^{(1)}\}$ ，  $D_2 = \{\mathbf{x}_1^{(2)}, \dots, \mathbf{x}_{n_2}^{(2)}\}$ ，投影直线的单位矢量为  $\mathbf{w}$ ， $d$  维空间的矢量  $\mathbf{x}$  在这条直线上的投影为一个标量：

$$y = \mathbf{w}^T \mathbf{x} \quad (1)$$

两类样本集经过投影之后成为标量集：  $D_1 \rightarrow \mathcal{J}_1 = \{y_1^{(1)}, \dots, y_{n_1}^{(1)}\}$ ，  $D_2 \rightarrow \mathcal{J}_2 = \{y_1^{(2)}, \dots, y_{n_2}^{(2)}\}$ 。不同类样本的分散程度越大，同类样本的聚集程度越高则类别之间的可分性越强。在 1 维空间中可以用两个类别样本均值之差的平方  $(\tilde{\mu}_1 - \tilde{\mu}_2)^2$  来度量两类样本的分散程度；而样本类内的离散程度可以用样本的方差之和来度量  $\tilde{s}_1^2 + \tilde{s}_2^2$ 。综合考虑类内的聚集程度和类间的分散程度，可以建立如下的 Fisher 准则：

$$J(\mathbf{w}) = \frac{(\tilde{\mu}_1 - \tilde{\mu}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2} \quad (2)$$

Fisher 准则函数的值越大，类别的可分性则越强。下面写出准则函数  $J(\mathbf{w})$  关于投影直线方向矢量  $\mathbf{w}$  的显式表达式，首先计算投影之后类别的均值  $\tilde{\mu}$ ：

$$\tilde{\mu}_i = \frac{1}{n_i} \sum_{y \in \mathcal{J}_i} y = \frac{1}{n_i} \sum_{\mathbf{x} \in D_i} \mathbf{w}^T \mathbf{x} = \mathbf{w}^T \boldsymbol{\mu}_i, \quad i = 1, 2 \quad (3)$$

投影之后两类均值之差的平方可以表示为：

$$(\tilde{\mu}_1 - \tilde{\mu}_2)^2 = (\mathbf{w}^T \boldsymbol{\mu}_1 - \mathbf{w}^T \boldsymbol{\mu}_2)^2 = \mathbf{w}^T (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \mathbf{w} = \mathbf{w}^T \mathbf{S}_b \mathbf{w} \quad (4)$$

其中  $\mathbf{S}_b = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T$  是类间散布矩阵（假设两类的先验概率相等）。类似的：

$$\begin{aligned}
\tilde{s}_i^2 &= \sum_{y \in \mathcal{Y}_i'} (y - \tilde{\mu}_i)^2 \\
&= \sum_{\mathbf{x} \in D_i} (\mathbf{w}'\mathbf{x} - \mathbf{w}'\boldsymbol{\mu}_i)^2 \\
&= \sum_{\mathbf{x} \in D_i} \mathbf{w}'(\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)' \mathbf{w} \\
&= \mathbf{w}'\mathbf{S}_i \mathbf{w}
\end{aligned}$$

其中  $\mathbf{S}_i = \sum_{\mathbf{x} \in D_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)'$  类似于类内散布矩阵。总的方差：

$$\tilde{s}_1^2 + \tilde{s}_2^2 = \mathbf{w}'\mathbf{S}_1 \mathbf{w} + \mathbf{w}'\mathbf{S}_2 \mathbf{w} = \mathbf{w}'(\mathbf{S}_1 + \mathbf{S}_2) \mathbf{w} = \mathbf{w}'\mathbf{S}_w \mathbf{w} \quad (5)$$

(4)、(5) 式代入 Fisher 准则，可以得到如下优化问题：

$$\max_{\mathbf{w}} J(\mathbf{w}) = \frac{(\tilde{\mu}_1 - \tilde{\mu}_2)^2}{\tilde{s}_1^2 + \tilde{s}_2^2} = \frac{\mathbf{w}'\mathbf{S}_b \mathbf{w}}{\mathbf{w}'\mathbf{S}_w \mathbf{w}} \quad (6)$$

上式也被称为是 Rayleigh 商的优化问题。实际上这个问题存在着无穷多个解，因为如果  $\mathbf{w}^*$  是一个最优解的话，对于任意的  $a \neq 0$ ， $a\mathbf{w}^*$  同样是最优解。我们真正关心的是投影矢量  $\mathbf{w}$  的方向，而不关心它的长度（可以规格化为单位矢量），因此可以通过适当调整  $\|\mathbf{w}\|$  使得 Fisher 准则的分母  $\mathbf{w}'\mathbf{S}_w \mathbf{w}$  等于一个常数  $C$ 。这样我们就得到了一个有约束的优化问题：

$$\max_{\mathbf{w}} J(\mathbf{w}) = \mathbf{w}'\mathbf{S}_b \mathbf{w} \quad (7)$$

约束：

$$\mathbf{w}'\mathbf{S}_w \mathbf{w} = C$$

构造 Lagrange 函数转化为无约束优化：

$$L(\mathbf{w}) = \mathbf{w}'\mathbf{S}_b \mathbf{w} - \lambda(\mathbf{w}'\mathbf{S}_w \mathbf{w} - C) \quad (8)$$

对  $\mathbf{w}$  求导：

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} = 2\mathbf{S}_b \mathbf{w} - 2\lambda \mathbf{S}_w \mathbf{w} = 0$$

因此有：

$$\mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w} \quad (9)$$

满足上式的  $\lambda$  和  $\mathbf{w}$  称为关于  $\mathbf{S}_b$  和  $\mathbf{S}_w$  的广义特征值和特征矢量，如果  $\mathbf{S}_w$  的逆矩阵存在的话，有：

$$\mathbf{S}_w^{-1} \mathbf{S}_b \mathbf{w} = \lambda \mathbf{w} \quad (10)$$

$\lambda$  和  $\mathbf{w}$  分别是矩阵  $\mathbf{S}_w^{-1} \mathbf{S}_b$  的特征值和对应的特征矢量。与主成分分析一样， $\mathbf{S}_w^{-1} \mathbf{S}_b$  是一个  $d \times d$  的方阵，存在  $d$  个特征值和  $d$  个特征矢量，哪一个特征矢量使得 Fisher 准则取得最大值？将满足 (9) 式的一个特征矢量  $\mathbf{w}_i$  代入 (6) 式：

$$J(\mathbf{w}) = \frac{\mathbf{w}_i' \mathbf{S}_b \mathbf{w}_i}{\mathbf{w}_i' \mathbf{S}_w \mathbf{w}_i} = \frac{\lambda_i \mathbf{w}_i' \mathbf{S}_w \mathbf{w}_i}{\mathbf{w}_i' \mathbf{S}_w \mathbf{w}_i} = \lambda_i \quad (11)$$

由此可见最大特征值对应的特征矢量是使得 Fisher 准则取得最大值的方向矢量。通过这样一个推导过程我们可以得出如下结论：两个类别的样本向一条直线上投影，当直线的方向矢量  $\mathbf{w}$  为矩阵  $\mathbf{S}_w^{-1} \mathbf{S}_b$  最大特征值对应的特征矢量时，可以使得投影之后样本在 1 维空间中

具有最大的可分性。

下面将这个问题推广到  $c$  个类别的样本向  $d'$  个方向上的投影，即将  $d$  维特征降维为  $d'$  个特征，使得降维之后的样本具有最大的可分性。首先定义矩阵：

$$\mathbf{S}_w = \sum_{i=1}^c \mathbf{S}_i, \quad \mathbf{S}_b = \sum_{i=1}^c n_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^t \quad (12)$$

其中  $\boldsymbol{\mu}$  为所有样本的均值矢量。可以证明使得 Fisher 准则最大的  $d'$  个投影矢量是对于矩阵  $\mathbf{S}_w^{-1}\mathbf{S}_b$  最大  $d'$  个特征值的特征矢量。

## ● KPCA 方法的推导

首先证明该样本集合协方差矩阵的特征向量处于样本所张成的空间，即：

$v \in \text{span}\{x_1, \dots, x_m\}$ ，设有样本集合： $X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ ，假设样本的均值为 0，即： $\sum_{i=1}^m \mathbf{x}_i = 0$ 。

**[证明]**

样本集合的协方差矩阵为： $C = \frac{1}{m} \sum_{j=1}^m x_j \cdot x_j^t$ ，令  $\lambda$  为  $C$  的特征值， $\mathbf{v}$  为对应特征矢量，则有：

$$\lambda \mathbf{v} = C\mathbf{v} = \left( \frac{1}{m} \sum_{j=1}^m \mathbf{x}_j \cdot \mathbf{x}_j^t \right) \mathbf{v} = \frac{1}{m} \sum_{j=1}^m (\mathbf{x}_j^t \mathbf{v}) \mathbf{x}_j \quad (1)$$

即：

$$\mathbf{v} = \frac{1}{m\lambda} \sum_{j=1}^m (\mathbf{x}_j^t \mathbf{v}) \mathbf{x}_j$$

因此： $v \in \text{span}\{x_1, \dots, x_m\}$ 。

证毕

下面来推导特征空间中协方差矩阵特征值和特征向量的求解方法。设有样本集合： $X = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ ，取非线性映射： $\phi: R^d \rightarrow \mathcal{F}$ ， $R^d$  为样本所处的  $d$  维欧氏空间，称为输入空间， $\mathcal{F}$  为一个 Hilbert 空间，称为特征空间，样本在特征空间中的内积可以用一个核函数来计算： $k(\mathbf{x}, \mathbf{y}) = (\phi(\mathbf{x}))^t \phi(\mathbf{y})$ 。假设样本集合在特征空间中的均值为 0，即： $\sum_{i=1}^m \phi(\mathbf{x}_i) = 0$ 。

样本在特征空间中的协方差矩阵为：

$$\bar{C} = \frac{1}{m} \sum_{i=1}^m \phi(\mathbf{x}_i) \phi^t(\mathbf{x}_i) \quad (2)$$

令： $\lambda$  为  $\bar{C}$  的特征值， $\mathbf{V}$  为对应的特征矢量，则有：

$$\lambda \mathbf{V} = \bar{C} \mathbf{V} \quad (3)$$

利用之前证明的结果，特征矢量  $\mathbf{V} \in \text{span}\{\phi(\mathbf{x}_1), \dots, \phi(\mathbf{x}_m)\}$ ，即存在  $\alpha_1, \dots, \alpha_m$ ，使得：

$$\mathbf{V} = \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \quad (4)$$

(4)式左乘  $\phi^t(\mathbf{x}_j)$ ，则有：

$$\lambda [\phi^t(\mathbf{x}_j) \cdot \mathbf{V}] = \phi^t(\mathbf{x}_j) \cdot \bar{C} \mathbf{V}, \quad j=1, \dots, m \quad (5)$$

将(4)式代入(5)式左端：

$$\begin{aligned} \lambda [\phi^t(\mathbf{x}_j) \cdot \mathbf{V}] &= \lambda \left( \sum_{i=1}^m \alpha_i \phi^t(\mathbf{x}_j) \phi(\mathbf{x}_i) \right) \\ &= \lambda \left( \sum_{i=1}^m \alpha_i k_{ji} \right) \\ &= \lambda (\mathbf{K} \boldsymbol{\alpha})_j \end{aligned} \quad (6)$$



其中：

$$\mathbf{K} = \left[ k(\mathbf{x}_i, \mathbf{x}_j) \right]_{m \times m} = \left( \phi^t(\mathbf{x}_i) \phi(\mathbf{x}_j) \right)_{m \times m}$$

$$\mathbf{a} = (\alpha_1, \dots, \alpha_m)^t$$

$(\mathbf{Ka})_j$  为矢量  $\mathbf{Ka}$  的第  $j$  个元素.

将(2)和(4)式代入(5)式的右端：

$$\begin{aligned} \phi^t(\mathbf{x}_j) \cdot \bar{\mathbf{C}} \mathbf{V} &= \phi^t(\mathbf{x}_j) \cdot \frac{1}{m} \sum_{l=1}^m \phi(\mathbf{x}_l) \phi^t(\mathbf{x}_l) \cdot \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i) \\ &= \frac{1}{m} \sum_{l=1}^m \sum_{i=1}^m \alpha_i \left( \phi^t(\mathbf{x}_j) \phi(\mathbf{x}_l) \cdot \phi^t(\mathbf{x}_l) \phi(\mathbf{x}_i) \right) \\ &= \frac{1}{m} \sum_{l=1}^m \sum_{i=1}^m \alpha_i k_{jl} k_{li} \\ &= \frac{1}{m} (\mathbf{K}^2 \mathbf{a})_j \end{aligned} \quad (7)$$

(6)式(7)式相等，则有：

$$\lambda \mathbf{Ka} = \frac{1}{m} \mathbf{K}^2 \mathbf{a} \quad (8)$$

因此，求取  $\bar{\mathbf{C}}$  的特征值和特征向量的问题可以转化为如下特征值问题：

$$m\lambda \mathbf{a} = \mathbf{Ka} \quad (9)$$

用  $\lambda$  代替  $m\lambda$ ，即为：

$$\lambda \mathbf{a} = \mathbf{Ka} \quad (10)$$

令： $\lambda^1, \dots, \lambda^m$  为矩阵  $\mathbf{K}$  的特征值， $\mathbf{a}^1, \dots, \mathbf{a}^m$  为特征矢量，则对应的  $\bar{\mathbf{C}}$  的第  $i$  个特征值和特征矢量为：

$$\lambda_i = \frac{\lambda^i}{m}, \quad \mathbf{V}_i = \sum_{j=1}^m \alpha_j^i \phi(\mathbf{x}_j) \quad (11)$$

其中  $\alpha_j^i$  为  $\mathbf{a}^i$  的第  $j$  个元素。

规范化，将  $\mathbf{V}_i$  转化为单位矢量。

$$\begin{aligned} (\mathbf{V}_i)^t \cdot \mathbf{V}_i &= \sum_{j,l=1}^m \alpha_j^i \alpha_l^i \left( \phi^t(\mathbf{x}_j) \cdot \phi(\mathbf{x}_l) \right) \\ &= \sum_{j,l=1}^m \alpha_j^i \alpha_l^i \cdot k(\mathbf{x}_j, \mathbf{x}_l) \\ &= (\mathbf{a}^i)^t \mathbf{Ka}^i \\ &= \lambda^i (\mathbf{a}^i)^t \mathbf{a}^i \\ &= \lambda^i \|\mathbf{a}^i\|^2 \\ &= 1 \end{aligned}$$

因此只须使  $\|\mathbf{a}^i\|^2 = \frac{1}{\lambda^i}$ ，即可使  $\mathbf{V}_i$  规范化。

计算样本  $\mathbf{x}$  在特征空间中第  $j$  个轴上的投影，利用(11)式，有：

$$\phi^t(\mathbf{x}) \mathbf{V}_j = \sum_{i=1}^m \alpha_i^j \phi^t(\mathbf{x}) \phi(\mathbf{x}_i) = \sum_{i=1}^m \alpha_i^j k(\mathbf{x}, \mathbf{x}_i) \quad (12)$$

**KPCA 算法:**

1. 计算矩阵:  $\mathbf{K} = \left[ k(\mathbf{x}_i, \mathbf{x}_j) \right]_{m \times m}$ ;
2. 计算  $\mathbf{K}$  的特征值和特征向量:  $\lambda^1, \dots, \lambda^m$ ,  $\mathbf{a}^1, \dots, \mathbf{a}^m$ , 取最大的前  $p$  个特征值  $\lambda^1, \lambda^2, \dots, \lambda^p$ ;
3. 规范化前  $p$  个特征向量, 使得  $\|\mathbf{a}^i\|^2 = \frac{1}{\lambda^i}$ ;
4. 利用(12)式可以计算样本  $\mathbf{x}$  的第  $j$  个核主成分。